

Documentación Workshop 3

Juan David Daza Rivera
2231551


Introducción

Este proyecto busca predecir el Happiness Score (puntuación de felicidad) de países utilizando datos de 2015 a 2019. El informe documenta el proceso completo, desde la carga y limpieza de datos hasta el entrenamiento de modelos de machine learning y la implementación de un flujo de streaming de datos con Kafka. El enfoque abarca el análisis exploratorio de datos (EDA), la construcción de un modelo predictivo, y el envío de datos en tiempo real para generar predicciones que se almacenan en una base de datos. El objetivo es identificar los factores clave que influyen en la felicidad global, desarrollar un modelo robusto, simplificado y generalizable, y habilitar un sistema de streaming que ingeste datos, genere predicciones, y guarde resultados.

El proyecto se organiza en cuatro fases principales:

1. **Análisis Exploratorio de Datos (EDA):** Carga, limpieza, unificación y análisis de datos para identificar patrones y seleccionar variables relevantes.
2. **Modelado:** Entrenamiento y evaluación de modelos de regresión para predecir el Happiness Score.
3. **Streaming:** Envío de datos en tiempo real con Kafka, desde un producer hasta un consumer que genera predicciones y las almacena.

Flujo de trabajo:



Contexto y Datos

Los datos provienen del World Happiness Report, un conjunto de cinco archivos CSV (uno por año, 2015–2019), cada uno con ~150–158 filas (países) y 9–13 columnas. Las variables principales incluyen:

- **Happiness Score:** Variable objetivo (rango ~2.7–7.8), que mide la felicidad promedio de un país.
- **Numéricas:** Economy (GDP per Capita), Family, Health (Life Expectancy), Freedom, Trust (Government Corruption), Generosity, Happiness Rank.
- **Categorías:** Country (~165 valores únicos), Region (~10 valores, e.g., Western Europe, Sub-Saharan Africa), Year (2015–2019).
- **Otras:** Variables específicas por año, como Standard Error (2015) o Confidence Intervals (2016–2017).

El desafío inicial es unificar datasets con diferencias en nombres y disponibilidad de columnas (e.g., Region falta en 2018–2019), preparar un dataset limpio para modelado, y diseñar un flujo de streaming que ingeste datos, genere predicciones, y las guarde en una base de datos.

Análisis Exploratorio de Datos (EDA)

1. Carga de Datos

Se cargan cinco archivos CSV (2015.csv, 2016.csv, 2017.csv, 2018.csv, 2019.csv), cada uno con ~156–158 países.

2. Exploración Inicial y Comparación

Se comparan las columnas de los datasets de 2015 a 2019 para detectar consistencias y discrepancias que puedan afectar la unificación posterior. Los archivos de 2015 a 2017 incluyen columnas como Region, Happiness Rank, y Dystopia Residual, que proporcionan información geográfica, de clasificación, y un componente de referencia para la felicidad, respectivamente. Sin embargo, los archivos de 2018 y 2019 presentan diferencias notables, como el uso de Country or region en lugar de Country y Perceptions of corruption en vez de Trust (Government Corruption). A pesar de estas variaciones, la columna Generosity permanece consistente en todos los años, manteniendo el mismo nombre y definición, lo que facilita su inclusión en el dataset unificado.

3. Limpieza de Datos

La limpieza de datos constituye una etapa fundamental en el análisis exploratorio de los datasets del World Happiness Report (2015–2019), ya que garantiza la calidad y consistencia de la información antes de proceder con la unificación y el modelado. En este proceso, se examinan minuciosamente los cinco archivos CSV para identificar valores faltantes que puedan afectar los análisis posteriores. Tras la verificación, se detecta que solo el dataset de 2018 presenta un valor nulo,

específicamente en la columna Perceptions of corruption, que corresponde a Trust (Government Corruption) en los años anteriores. Este único dato faltante se aborda en una etapa posterior mediante la aplicación de la función `dropna()`, eliminando la fila afectada para asegurar un dataset completo.

4. Estandarización y Unificación

Para crear un dataset unificado a partir de los cinco archivos CSV del World Happiness Report (2015–2019), se realiza un proceso integral que estandariza y combina la información, asegurando consistencia y calidad para el análisis.

- Se renombran columnas en 2018–2019 (e.g., Score → Happiness Score, Country or region → Country) para alinearlas con 2015–2017.
- Se seleccionan columnas comunes: Country, Happiness Score, Economy (GDP per Capita), Family (o Social support), Health (Life Expectancy), Freedom, Trust (Government Corruption) (o Perceptions of corruption), Generosity, Happiness Rank, Region (disponible en 2015–2017).
- Se añade una columna Year (2015–2019) para identificar el año de cada registro.
- Se combinan los datasets en un único DataFrame, `df_unido`, con ~782 filas.
- Se mapea Region para 2018–2019, asignando la región más común de 2015–2017 por país; para 6 países (e.g., Trinidad & Tobago), se asignan regiones manualmente (e.g., Latin America and Caribbean).
- Se eliminan valores nulos, incluido el detectado en Perceptions of corruption (2018), mediante `dropna()`.

La siguiente tabla presenta las 10 columnas seleccionadas preliminarmente para el dataset unificado `df_unido`, junto con una breve descripción de cada una.

Columna	Descripción
Country	Nombre del país (o región en 2018–2019), identifica cada registro.
Happiness Score	Puntuación promedio de felicidad, variable objetivo (rango ~2.7–7.8).
Economy (GDP per Capita)	Contribución del PIB per cápita a la felicidad, normalizada (~0–2).

Family	Apoyo social o cohesión familiar, normalizada (~0–2).
Health (Life Expectancy)	Esperanza de vida saludable, normalizada (~0–2).
Freedom	Libertad para tomar decisiones de vida, normalizada (~0–2).
Trust (Government Corruption)	Percepción de corrupción gubernamental, normalizada (~0–2).
Generosity	Nivel de generosidad, normalizado (~0–2).
Happiness Rank	Ranking de felicidad, derivado de Happiness Score.
Region	Región geográfica (e.g., Western Europe), mapeada para 2018–2019.
Year	Año del registro (2015–2019), añadido para identificar temporalidad.

5. Análisis Descriptivo

En el análisis descriptivo del dataset unificado del World Happiness Report (2015–2019), se calculan estadísticas como media, mediana, mínimo, máximo y desviación estándar para las variables numéricas, junto con frecuencias para las variables categóricas, con el objetivo de comprender las distribuciones de los datos y detectar posibles anomalías que puedan influir en el análisis exploratorio.

	count	mean	std	min	25%	50%	75%	max
Happiness Score	783.0	5.382820	1.129122	2.839	4.503500	5.33200	6.208500	7.76900
Economy (GDP per Capita)	783.0	0.908532	0.402889	0.000	0.611510	0.97438	1.230555	1.82427
Happiness Rank	783.0	78.968072	45.275121	1.000	40.000000	79.00000	118.000000	158.00000
Family	783.0	0.999804	0.337583	0.000	0.790425	1.03143	1.240090	1.64400
Freedom	783.0	0.403670	0.152909	0.000	0.305000	0.41900	0.524500	0.72400
Trust (Government Corruption)	783.0	0.128338	0.107764	0.000	0.054500	0.09314	0.161800	0.55191
Generosity	783.0	0.217838	0.122026	0.000	0.130000	0.20180	0.275355	0.81971
Health (Life Expectancy)	783.0	0.613445	0.246701	0.000	0.440305	0.64718	0.808000	1.14100
Year	783.0	2016.992337	1.416000	2015.000	2016.000000	2017.00000	2018.000000	2019.00000

Los resultados revelan que Happiness Score, la variable objetivo, presenta una media de aproximadamente 5.4, un rango de 2.7 a 7.8, y una distribución ligeramente sesgada, mientras que las variables Economy (GDP per Capita), Health (Life Expectancy) y Family (o Social support), normalizadas en un rango de ~0 a 2, muestran medias entre 0.8 y 1.0, indicando valores moderados a altos; por otro lado, Trust (Government Corruption) y Generosity exhiben medias bajas, entre 0.1 y 0.2, sugiriendo menor variabilidad.

En las variables categoricas

	count	unique	top	freq
Country	783	168	Switzerland	5
Region	783	10	Sub-Saharan Africa	195


en las variables categóricas, Country abarca aproximadamente 165 países únicos, reflejando una amplia cobertura geográfica, y Region, con 10 categorías, identifica a Sub-Saharan Africa como la más frecuente,

6. Detección de Valores Atípicos

se emplea el método del rango intercuartílico (IQR) para identificar valores atípicos en las variables numéricas, como Happiness Score, Economy (GDP per Capita), Health (Life Expectancy), Family, Freedom, Trust (Government Corruption), y Generosity, tras aplicar este método, se detectan pocos valores atípicos, los cuales se consideran plausibles, ya que corresponden a casos esperados, como países con niveles de felicidad excepcionalmente altos o bajos, y, por lo tanto, se decide no eliminarlos, manteniendo la integridad de los datos para las etapas posteriores de análisis y procesamiento.


7. Visualizaciones

Histogramas de Variables Numéricas



Se elaboraron histogramas para analizar la distribución de variables numéricas como Happiness Score, Economy, Health, Family, Freedom, Trust y Generosity. Se observó que el Happiness Score tiene una distribución centrada en su media (~5.4), con un ligero sesgo a la izquierda. Economy, Health y Family presentan distribuciones más uniformes y medias entre 0.8 y 1.0, indicando valores consistentes entre países. En cambio, Trust y Generosity muestran medias bajas (~0.1–0.2) y distribuciones sesgadas hacia valores pequeños, lo que sugiere poca presencia de estos factores.


Gráfico de Barras de los 30 Países Menos Frecuentes



Se presentan los 30 países con menor frecuencia en el dataset entre 2015 y 2019,


revelando que muchos aparecen solo en 3 o 4 de los 5 años, lo que refleja inconsistencias en la recolección de datos o cambios en nombres de países. Con ~165 países únicos, esta alta cardinalidad limita el uso de Country como variable predictiva.

Boxplots de Happiness Score por Región y Año








Se utilizan boxplots para analizar el Happiness Score según las variables Region y Year. Los resultados muestran diferencias claras entre regiones: Western Europe y North America presentan medianas altas (~7–8) y baja dispersión, mientras que Sub-Saharan Africa tiene medianas bajas (~3–4) y mayor variabilidad. En contraste, los boxplots por Year revelan medianas estables (~5.4) y poca variación entre 2015 y 2019.

Mapa de Calor de Correlaciones entre Numéricas



Se genera un mapa de calor con la correlación de Pearson entre variables numéricas. Happiness Score muestra alta correlación con Economy, Health y Family, destacándolas como predictores clave. Freedom tiene correlación moderada igual a Trust y especialmente Generosity presentan correlaciones bajas, justificando la exclusión de esta última. Happiness Rank se elimina por su correlación negativa casi perfecta con Happiness Score (-0.99), lo que indica redundancia.

Gráficos de Dispersión de Happiness Score vs. Variables Numéricas



Se crean gráficos de dispersión para analizar la relación entre Happiness Score y variables numéricas. Se observa una fuerte relación positiva con Economy, Health y Family, mientras que Freedom muestra una relación más débil y Trust y Generosity presentan poca asociación. Estos resultados refuerzan los hallazgos del mapa de calor, destacando a Economy y Health como predictores clave y respaldando la exclusión de Generosity. Además, la dispersión de los puntos entre países justifica incluir la variable Region para capturar diferencias geográficas.

Conclusion

Las visualizaciones colectivamente confirman la relevancia de Region, Economy (GDP per Capita), y Health (Life Expectancy) como factores clave que influyen en

Happiness Score, respaldando su inclusión en el modelado. La estabilidad de Happiness Score entre los años 2015–2019, observada en los boxplots por Year, justifica la exclusión recomendada de Year como predictor.

8. Selección de Características

```
Características seleccionadas: ['Economy (GDP per Capita)', 'Family', 'Freedom', 'Trust (Government Corruption)', 'Health (Life Expectancy)']
```

Para identificar las variables numéricas más relevantes en la predicción de Happiness Score en el dataset del World Happiness Report (2015–2019), se aplica el método SelectKBest con `f_regression`, seleccionando Economy (GDP per Capita), Family, Health (Life Expectancy), Freedom, y Trust (Government Corruption) por su alta relevancia, mientras que Generosity se excluye debido a su menor impacto,

9. Análisis de Categóricas (ANOVA)

Resultados de ANOVA:

ANOVA para Region: $F=138.5278$, $p\text{-value}=1.1250e-154$

ANOVA para Year: $F=0.0272$, $p\text{-value}=9.9857e-01$

ANOVA para Country: $F=100.8238$, $p\text{-value}=0.0000e+00$

Mediante ANOVA, se evalúa la significancia de las variables categóricas Region, Year y Country en el dataset del (2015–2019) para decidir su inclusión; Region resulta muy significativa ($F=138.5278$, $p\text{-value}=1.1250e-154$) y se codifica en 10 columnas, Year no es significativa ($F=0.0272$, $p\text{-value}=0.99857$) y se recomienda excluir pese a su codificación, mientras que Country, aunque significativa ($p\text{-value}=0$), se descarta por su alta cardinalidad (~165 valores),

10. Codificación y Eliminación

Para preparar un dataset numérico apto para el modelado en el World Happiness Report (2015–2019), se aplica one-hot encoding a Region, generando 10 columnas, y a Year, creando 5 columnas, mientras que se eliminan Generosity, Happiness Rank, Country, y posteriormente Year por su baja significancia, resultando en `df_encoded` con 15 columnas predictivas (5 numéricas: Economy, Family, Health, Freedom, Trust; 10 de Region_) y Happiness Score como variable objetivo.

11. Guardado

```
df_encoded.to_csv('../data/processed/df_clean.csv', index=False)
```

Se guarda `df_encoded` como `df_clean.csv`.

4. Modelado

El modelado se realiza en el script 002_ML.ipynb, entrenando y evaluando múltiples modelos de regresión para predecir Happiness Score.

1. Preparación de Datos

La preparación de datos para el modelado del *World Happiness Report (2015–2019)* inicia con la carga del dataset limpio `df_clean.csv`. Se seleccionan 15 variables predictoras (5 numéricas y 10 categóricas codificadas por región) y Happiness Score como variable objetivo. Los datos se dividen en entrenamiento (70%) y prueba (30%) con `random_state=42`. Las variables numéricas se estandarizan con `StandardScaler`, mientras que las categóricas ya están codificadas. El resultado son conjuntos `X_train_encoded`, `X_test_encoded`, `y_train` y `y_test`,

2. Entrenamiento y Evaluación

Se entrenan siete modelos:

- Random Forest Regressor
- XGBoost Regressor
- Support Vector Regressor (SVR)
- k-Nearest Neighbors Regressor
- Lasso Regression
- Gradient Boosting Regressor
- Linear Regression


aplicación en el análisis predictivo y streaming con Kafka.

Modelo	R ² Score	MSE	MAE
XGBoost Regressor	0.8786	0.1514	0.2523
Random Forest Regressor	0.8699	0.1623	0.2935
Support Vector Regressor	0.8489	0.1885	0.3195
Gradient Boosting Regressor	0.8370	0.2034	0.3328

k-Nearest Neighbors Regressor	0.8314	0.2104	0.3512
Linear Regression	0.7791	0.2756	0.3965
Lasso Regression	0.7226	0.3462	0.4549


el mejor modelo alcanza un R^2 de 0.8786, explicando aproximadamente el 87.86% de la varianza, con los valores más bajos de MSE y MAE.

4. Importancia de Características



se evaluó la importancia de las variables predictivas en el modelo XGBoost del *World Happiness Report* (2015–2019), revelando que las más influyentes son Region_Latin America and Caribbean, Economy (GDP per Capita), Region_Eastern Asia, y Health (Life Expectancy). Variables como Freedom y otras regiones aportan de forma moderada, mientras que Family, Trust, y algunas regiones tienen baja relevancia.

Gráfico de Valores Reales vs. Predichos



Se creó un gráfico de dispersión comparando los valores reales y predichos de Happiness Score por el modelo XGBoost, mostrando una alta precisión con un R^2 de 0.8786. La mayoría de los puntos se agrupan cerca de la línea ideal $y = x$, indicando que el modelo explica cerca del 88% de la varianza y predice bien la felicidad de los países. Las pequeñas desviaciones corresponden a casos extremos y la gráfica valida la robustez del modelo, destacando la importancia de variables como Economy y Health.

5. Guardado del Modelo

```
joblib.dump(model_XGB, '../models/happiness_model_XGB.pkl')
```

El modelo XGBoost, el mejor para predecir Happiness Score, se guarda en el archivo happiness_model_XGB.pkl con joblib para reutilización futura. Esto permite integrarlo eficientemente en pipelines predictivos y en flujo de streaming con Kafka.

5. Streaming con Kafka del World Happiness Report

El flujo de streaming con Apache Kafka permite procesar datos en tiempo real, integrando el modelo predictivo XGBoost (happiness_model_XGB.pkl) para generar predicciones de Happiness Score y almacenarlas en una base de datos PostgreSQL, complementando el análisis exploratorio y el modelado. Este proceso abarca la configuración de Kafka, la producción de datos desde df_clean.csv, el consumo de mensajes con predicciones, el

almacenamiento de resultados, y el monitoreo de métricas, asegurando un pipeline robusto y escalable para aplicaciones predictivas en tiempo real.


Componentes clave del pipeline:

1. Configuración de Kafka:

- Kafka opera en `localhost:9092` (posiblemente en Docker), con el topic `happiness-topic`.
- Se transmite cada mensaje con 15 variables predictivas (5 numéricas y 10 codificadas por región) y el valor real del *Happiness Score*.
- El consumidor usa `group_id= 'happiness_group'` y parámetros para estabilidad y procesamiento completo desde el inicio.

2. Producción de datos:

- Un script (`producer.py`) envía datos desde `df_clean.csv` (782 filas) como mensajes JSON cada segundo.
- Se simula un flujo continuo de datos, capturando las variables predictoras y el valor real de felicidad.



```
identified as 2.6
2025-05-23 21:52:56,296 - INFO - <BrokerConnection client_id=kafka-python-producer-1, node_id=bootstrap-0 host=localhost:9092 <connected> [IPv4 ('127.0.0.1', 9092)]>: Connection complete.
2025-05-23 21:52:56,482 - INFO - <BrokerConnection client_id=kafka-python-producer-1, node_id=1 host=localhost:9092 <connecting> [IPv4 ('127.0.0.1', 9092)]>: connecting to localhost:9092 [('127.0.0.1', 9092) IPv4]
2025-05-23 21:52:56,483 - INFO - <BrokerConnection client_id=kafka-python-producer-1, node_id=1 host=localhost:9092 <connected> [IPv4 ('127.0.0.1', 9092)]>: Connection complete.
2025-05-23 21:52:56,483 - INFO - <BrokerConnection client_id=kafka-python-producer-1, node_id=bootstrap-0 host=localhost:9092 <connected> [IPv4 ('127.0.0.1', 9092)]>: closing connection.
2025-05-23 21:52:56,417 - INFO - Mensaje 0 enviado a Kafka: {'index': 0, 'features': {'freedom': 0.66557, 'Trust (Government Corruption)': 0.41978, 'Family': 1.34951, 'Economy (GDP per Capita)': 1.39051, 'Health (Life Expectancy)': 0.94143, 'Region.Western Europe': 1.0, 'Region.North America': 0.0, 'Region.Australia and New Zealand': 0.0, 'Region.Middle East and Northern Africa': 0.0, 'Region.Latin America and Caribbean': 0.0, 'Region.Southeastern Asia': 0.0, 'Region.Central and Eastern Europe': 0.0, 'Region.Eastern Asia': 0.0, 'Region.Southern Asia': 0.0, 'Region.Sub-Saharan Africa': 0.0}, 'y_test': 7.587}
2025-05-23 21:52:57,423 - INFO - Mensaje 1 enviado a Kafka: {'index': 1, 'features': {'Freedom': 0.62877, 'Trust (Government Corruption)': 0.14145, 'Family': 1.40223, 'Economy (GDP per Capita)': 1.30232, 'Health (Life Expectancy)': 0.94784, 'Region.Western Europe': 1.0, 'Region.North America': 0.0, 'Region.Australia and New Zealand': 0.0, 'Region.Middle East and Northern Africa': 0.0, 'Region.Latin America and Caribbean': 0.0, 'Region.Southeastern Asia': 0.0, 'Region.Central and Eastern Europe': 0.0, 'Region.Eastern Asia': 0.0, 'Region.Southern Asia': 0.0, 'Region.Sub-Saharan Africa': 0.0}, 'y_test': 7.561}
2025-05-23 21:52:58,425 - INFO - Mensaje 2 enviado a Kafka: {'index': 2, 'features': {'Freedom': 0.64938, 'Trust (Government Corruption)': 0.48357, 'Family': 1.36958, 'Economy (GDP per Capita)': 1.32548, 'Health (Life Expectancy)': 0.87464, 'Region.Western Europe': 1.0, 'Region.North America': 0.0, 'Region.Australia and New Zealand': 0.0, 'Region.Middle East and Northern Africa': 0.0, 'Region.Latin America and Caribbean': 0.0, 'Region.Southeastern Asia': 0.0, 'Region.Central and Eastern Europe': 0.0, 'Region.Eastern Asia': 0.0, 'Region.Southern Asia': 0.0, 'Region.Sub-Saharan Africa': 0.0}, 'y_test': 7.527}
2025-05-23 21:52:59,428 - INFO - Mensaje 3 enviado a Kafka: {'index': 3, 'features': {'Freedom': 0.66973, 'Trust (Government Corruption)': 0.36503, 'Family': 1.33095, 'Economy (GDP per Capita)': 1.459, 'Health (Life Expectancy)': 0.88521, 'Region.Western Europe': 1.0, 'Region.North America': 0.0, 'Region.Australia and New Zealand': 0.0, 'Region.Middle East and Northern Africa': 0.0, 'Region.Latin America and Caribbean': 0.0, 'Region.Southeastern Asia': 0.0, 'Region.Central and Eastern Europe': 0.0, 'Region.Eastern Asia': 0.0, 'Region.Southern Asia': 0.0, 'Region.Sub-Saharan Africa': 0.0}, 'y_test': 7.522}
2025-05-23 21:53:00,429 - INFO - Mensaje 4 enviado a Kafka: {'index': 4, 'features': {'Freedom': 0.63297, 'Trust (Government Corruption)': 0.32957, 'Family': 1.32261, 'Economy (GDP per Capita)': 1.32629, 'Health (Life Expectancy)': 0.90563, 'Region.Western Europe': 0.0, 'Region.North America': 1.0, 'Region.Australia and New Zealand': 0.0, 'Region.Middle East and Northern Africa': 0.0, 'Region.Latin America and Caribbean': 0.0, 'Region.Southeastern Asia': 0.0, 'Region.Central and Eastern Europe': 0.0, 'Region.Eastern Asia': 0.0, 'Region.Southern Asia': 0.0, 'Region.Sub-Saharan Africa': 0.0}, 'y_test': 7.427}
2025-05-23 21:53:01,430 - INFO - Mensaje 5 enviado a Kafka: {'index': 5, 'features': {'Freedom': 0.64169, 'Trust (Government Corruption)': 0.41372, 'Family': 1.31826, 'Economy (GDP per Capita)': 1.29025, 'Health (Life Expectancy)': 0.88911, 'Region.Western Europe': 1.0, 'Region.North America': 0.0, 'Region.Australia and New Zealand': 0.0, 'Region.Middle East and Northern Africa': 0.0, 'Region.Latin America and Caribbean': 0.0, 'Region.Southeastern Asia': 0.0, 'Region.Central and Eastern Europe': 0.0, 'Region.Eastern Asia': 0.0, 'Region.Southern Asia': 0.0, 'Region.Sub-Saharan Africa': 0.0}, 'y_test': 7.406}
```

3. Consumo y predicción:

- El script `consumer.py` consume los mensajes, carga el modelo XGBoost y genera predicciones en tiempo real.
- Las predicciones se hacen tras validar y ordenar las variables.

```
frica': 0.0), 'y_test': 6.901}
2025-05-23 21:53:42,684 - INFO - ✓ Predicción guardada en PostgreSQL: {'index': 19, 'features': {'Freedom': 0.64157, 'Trust (Government Corruption)': 0.38583, 'Family': 1.12575, 'Economy (GDP per Capita)': 1.42277, 'Health (Life Expectancy)': 0.80925, 'Region Western Europe': 0.0, 'Region North America': 0.0, 'Region Australia and New Zealand': 0.0, 'Region Middle East and Northern Africa': 1.0, 'Region Latin America and Caribbean': 0.0, 'Region Southeastern Asia': 0.0, 'Region Central and Eastern Europe': 0.0, 'Region Eastern Asia': 0.0, 'Region Southern Asia': 0.0, 'Region Sub-Saharan Africa': 0.0}, 'y_test': 6.901, 'y_pred': 6.656632423400879}
2025-05-23 21:53:42,785 - INFO - Mensaje recibido: {'index': 20, 'features': {'Freedom': 0.59625, 'Trust (Government Corruption)': 0.32067, 'Family': 1.28548, 'Economy (GDP per Capita)': 1.26637, 'Health (Life Expectancy)': 0.90943, 'Region Western Europe': 1.0, 'Region North America': 0.0, 'Region Australia and New Zealand': 0.0, 'Region Middle East and Northern Africa': 0.0, 'Region Latin America and Caribbean': 0.0, 'Region Southeastern Asia': 0.0, 'Region Central and Eastern Europe': 0.0, 'Region Eastern Asia': 0.0, 'Region Southern Asia': 0.0, 'Region Sub-Saharan Africa': 0.0}, 'y_test': 6.867}
2025-05-23 21:53:42,859 - INFO - ✓ Predicción guardada en PostgreSQL: {'index': 20, 'features': {'Freedom': 0.59625, 'Trust (Government Corruption)': 0.32067, 'Family': 1.28548, 'Economy (GDP per Capita)': 1.26637, 'Health (Life Expectancy)': 0.90943, 'Region Western Europe': 1.0, 'Region North America': 0.0, 'Region Australia and New Zealand': 0.0, 'Region Middle East and Northern Africa': 0.0, 'Region Latin America and Caribbean': 0.0, 'Region Southeastern Asia': 0.0, 'Region Central and Eastern Europe': 0.0, 'Region Eastern Asia': 0.0, 'Region Southern Asia': 0.0, 'Region Sub-Saharan Africa': 0.0}, 'y_test': 6.867, 'y_pred': 6.827025413513184}
2025-05-23 21:53:42,961 - INFO - Mensaje recibido: {'index': 21, 'features': {'Freedom': 0.63274, 'Trust (Government Corruption)': 0.32524, 'Family': 1.08182, 'Economy (GDP per Capita)': 1.36811, 'Health (Life Expectancy)': 0.76276, 'Region Western Europe': 0.0, 'Region North America': 0.0, 'Region Australia and New Zealand': 0.0, 'Region Middle East and Northern Africa': 1.0, 'Region Latin America and Caribbean': 0.0, 'Region Southeastern Asia': 0.0, 'Region Central and Eastern Europe': 0.0, 'Region Eastern Asia': 0.0, 'Region Southern Asia': 0.0, 'Region Sub-Saharan Africa': 0.0}, 'y_test': 6.853}
2025-05-23 21:53:43,028 - INFO - ✓ Predicción guardada en PostgreSQL: {'index': 21, 'features': {'Freedom': 0.63274, 'Trust (Government Corruption)': 0.32524, 'Family': 1.08182, 'Economy (GDP per Capita)': 1.36811, 'Health (Life Expectancy)': 0.76276, 'Region Western Europe': 0.0, 'Region North America': 0.0, 'Region Australia and New Zealand': 0.0, 'Region Middle East and Northern Africa': 1.0, 'Region Latin America and Caribbean': 0.0, 'Region Southeastern Asia': 0.0, 'Region Central and Eastern Europe': 0.0, 'Region Eastern Asia': 0.0, 'Region Southern Asia': 0.0, 'Region Sub-Saharan Africa': 0.0}, 'y_test': 6.853, 'y_pred': 6.5578532218933185}
2025-05-23 21:53:43,129 - INFO - Mensaje recibido: {'index': 22, 'features': {'Freedom': 0.42908, 'Trust (Government Corruption)': 0.11069, 'Family': 1.25596, 'Economy (GDP per Capita)': 1.04424, 'Health (Life Expectancy)': 0.72052, 'Region Western Europe': 0.0, 'Region North America': 0.0, 'Region Australia and New Zealand': 0.0, 'Region Middle East and Northern Africa': 0.0, 'Region Latin America and Caribbean': 1.0, 'Region Southeastern Asia': 0.0, 'Region Central and Eastern Europe': 0.0, 'Region Eastern Asia': 0.0, 'Region Southern Asia': 0.0, 'Region Sub-Saharan Africa': 0.0}, 'y_test': 6.81}
```

4. Almacenamiento en PostgreSQL:

- Las predicciones se guardan en la tabla happiness_predictions usando sqlalchemy.
- Se almacenan el índice, variables, valor real y predicción, con control de errores para asegurar persistencia de datos.

```
res
y_pred | y_test |
-----+-----
2580 | 782 | {"Freedom": 0.01, "Trust (Government Corruption)": 0.091, "Family": 0.575, "Economy (GDP per Capita)": 0.386, "Health (Life Expectancy)": 0.295, "Year 2015": 0.0, "Year 2016": 0.0, "Year 2017": 0.0, "Year 2018": 0.0, "Year 2019": 1.0, "Region Western Europe": 0.0, "Region North America": 0.0, "Region Australia and New Zealand": 0.0, "Region Middle East and Northern Africa": 0.0, "Region Latin America and Caribbean": 0.0, "Region Southeastern Asia": 0.0, "Region Central and Eastern Europe": 0.0, "Region Eastern Asia": 0.0, "Region Southern Asia": 0.0, "Region Sub-Saharan Africa": 1.0} | 2.853 | 4.81398865669791
3323 | 782 | {"Freedom": 0.01, "Trust (Government Corruption)": 0.091, "Family": 0.575, "Economy (GDP per Capita)": 0.386, "Health (Life Expectancy)": 0.295, "Region Western Europe": 0.0, "Region North America": 0.0, "Region Australia and New Zealand": 0.0, "Region Middle East and Northern Africa": 0.0, "Region Latin America and Caribbean": 0.0, "Region Southeastern Asia": 0.0, "Region Central and Eastern Europe": 0.0, "Region Eastern Asia": 0.0, "Region Southern Asia": 0.0, "Region Sub-Saharan Africa": 1.0} | 2.853 | 4.774255275726318
3322 | 781 | {"Freedom": 0.225, "Trust (Government Corruption)": 0.035, "Family": 0.0, "Economy (GDP per Capita)": 0.026, "Health (Life Expectancy)": 0.105, "Region Western Europe": 0.0, "Region North America": 0.0, "Region Australia and New Zealand": 0.0, "Region Middle East and Northern Africa": 0.0, "Region Latin America and Caribbean": 0.0, "Region Southeastern Asia": 0.0, "Region Central and Eastern Europe": 0.0, "Region Eastern Asia": 0.0, "Region Southern Asia": 0.0, "Region Sub-Saharan Africa": 1.0} | 3.083 | 4.671288869908879
2539 | 781 | {"Freedom": 0.225, "Trust (Government Corruption)": 0.035, "Family": 0.0, "Economy (GDP per Capita)": 0.026, "Health (Life Expectancy)": 0.105, "Year 2015": 0.0, "Year 2016": 0.0, "Year 2017": 0.0, "Year 2018": 0.0, "Year 2019": 1.0, "Region Western Europe": 0.0, "Region North America": 0.0, "Region Australia and New Zealand": 0.0, "Region Middle East and Northern Africa": 0.0, "Region Latin America and Caribbean": 0.0, "Region Southeastern Asia": 0.0, "Region Central and Eastern Europe": 0.0, "Region Eastern Asia": 0.0, "Region Southern Asia": 0.0, "Region Sub-Saharan Africa": 1.0} | 3.083 | 4.6705802784729
2539 | 788 | {"Freedom": 0.0, "Trust (Government Corruption)": 0.025, "Family": 0.517, "Economy (GDP per Capita)": 0.35, "Health (Life Expectancy)": 0.361, "Year 2015": 0.0, "Year 2016": 0.0, "Year 2017": 0.0, "Year 2018": 0.0, "Year 2019": 1.0, "Region Western Europe": 0.0, "Region North America": 0.0, "Region Australia and New Zealand": 0.0, "Region Middle East and Northern Africa": 0.0, "Region Latin America and Caribbean": 0.0, "Region Southeastern Asia": 0.0, "Region Central and Eastern Europe": 0.0, "Region Eastern Asia": 0.0, "Region Southern Asia": 1.0, "Region Sub-Saharan Africa": 0.0} | 3.203 | 4.9515889262916
3321 | 788 | {"Freedom": 0.0, "Trust (Government Corruption)": 0.025, "Family": 0.517, "Economy (GDP per Capita)": 0.35, "Health (Life Expectancy)": 0.361, "Region Western Europe": 0.0, "Region North America": 0.0, "Region Australia and New Zealand": 0.0, "Region Middle East and Northern Africa": 0.0, "Region Latin America and Caribbean": 0.0, "Region Southeastern Asia": 0.0, "Region Central and Eastern Europe": 0.0, "Region Eastern Asia": 0.0, "Region Southern Asia": 1.0, "Region Sub-Saharan Africa": 0.0} | 3.203 | 5.359049320228947
3320 | 779 | {"Freedom": 0.417, "Trust (Government Corruption)": 0.147, "Family": 0.885, "Economy (GDP per Capita)": 0.076, "Health (Life Expectancy)": 0.109, "Region Western Europe": 0.0, "Region North America": 0.0, "Region Australia and New Zealand": 0.0, "Region Middle East and Northern Africa": 0.0, "Region Latin America and Caribbean": 0.0, "Region Southeastern Asia": 0.0, "Region Central and Eastern Europe": 0.0, "Region Eastern Asia": 0.0, "Region Southern Asia": 0.0, "Region Sub-Saharan Africa": 1.0} | 3.203 | 5.359049320228947
```

5. Monitoreo de métricas:

- Se calcula el *Mean Squared Error* (MSE) en tiempo real entre valores reales y predichos.
- Este monitoreo asegura que el modelo mantiene precisión (MSE ~ 0.1514, R^2 ~ 0.8786) y detecta desviaciones para posibles reentrenamientos.

6. Conclusiones

El proyecto desarrolla un pipeline predictivo que estima el Happiness Score con una precisión del 87.86% ($R^2 = 0.8786$) utilizando XGBoost, identificando como variables más influyentes a Region_Latin America and Caribbean (~33.31%), Economy (GDP per Capita) (~21.71%) y Health (Life Expectancy) (~9.46%).se detalla un análisis exploratorio de datos

(EDA) que limpió y unificó 782 registros, resolviendo inconsistencias como la ausencia de la variable región en los años 2018–2019 mediante mapeo manual, y seleccionando 15 variables predictivas óptimas tras excluir otras como Generosity, Country y Family por baja relevancia. Las visualizaciones gráficas ayudaron a identificar patrones como la estabilidad del puntaje de felicidad (~5.4 de media), correlaciones fuertes con la economía y salud (~0.7–0.8), y variabilidad regional significativa. Se profundiza en la importancia de características dentro del modelo, mientras que en tambein se describe la implementación de un sistema de predicción en tiempo real usando Apache Kafka, que transmite datos desde df_clean.csv al topic happiness-topic, procesa predicciones con el modelo happiness_model_XGB.pkl, y guarda resultados en PostgreSQL, todo bajo monitoreo constante del error cuadrático medio (MSE). Este enfoque integral demuestra la solidez del análisis predictivo, la utilidad de un EDA detallado y la escalabilidad del sistema para análisis en tiempo real.